



Tecnológico Nacional de México

Instituto Tecnológico de Morelia

Departamento de Sistemas y Computación

Inteligencia Artificial

Protocolo de Investigación Tecnológica

Pronóstico Univariado de Demanda Eléctrica mediante la Arquitectura N-BEATS

Autor(es):

Carlos Andrés Álvarez Arreygue
José Alberto Vázquez Oropeza

Asesor(a):

Felipe Morales López

Morelia, Michoacán; a <<...>> de <<...>> de 2025

Índice

Introducción.....	2
Antecedentes y contexto.....	3
Palabras clave.....	4
Enunciado del problema de investigación.....	5
Objetivos de la investigación	5
Objetivo general.....	5
Objetivos específicos	5
Justificación.....	5
Bosquejo de marco de referencia / marco teórico.....	7
Hipótesis	7
Bosquejo del método	8
Determinación del universo y obtención de la muestra	8
Determinación del tipo de investigación.....	8
Selección, diseño y prueba del instrumento de recolección.....	8
Plan de recolección de información	8
Plan de procesamiento y análisis de información	8
Gestión del proyecto	9
Etapa 1. Preparación teórica y metodológica.....	9
Etapa 2. Obtención y preparación de datos.....	9
Etapa 3. Modelado y evaluación	9
Etapa 4. Desarrollo de la aplicación de escritorio.....	10
Etapa 5. Redacción, revisión y entrega del informe final	10
Productos entregables	10
Vinculaciones estratégicas y lugar(es) de desarrollo del proyecto	11
Estrategias de comunicación.....	11
Fuentes consultadas	11

Introducción

Antecedentes y contexto

La gran importancia de la electricidad en la vida del hombre ha motivado a un gran número de empresas a crear modelos estructurales o basados en costeo para obtener estimaciones de sus costos futuros (Velásquez y Souza, 2007).

La energía eléctrica constituye un pilar fundamental para el desarrollo económico y el bienestar social. En la actualidad, resulta difícil concebir una sociedad moderna sin un suministro eléctrico confiable dada la fuerte dependencia tecnológica que caracteriza la productividad, la industria y los servicios básicos. Diversos estudios han demostrado que el consumo eléctrico está estrechamente relacionado con el índice de desarrollo humano, al reflejar el grado de avance tecnológico y social de una nación (Niu et al., 2013).

Durante las últimas décadas, los sistemas eléctricos han incrementado notablemente su complejidad debido a la integración de la tecnología en casi todos los aspectos de la vida cotidiana. En este contexto, surge la necesidad de garantizar estabilidad, fiabilidad y eficiencia ante una demanda energética cada vez más variable. El desarrollo de redes eléctricas inteligentes (smart grids) ha permitido mejorar la eficiencia del suministro, reducir costos y maximizar la confiabilidad mediante sistemas de comunicación digital que integran generación, transmisión y consumo en tiempo real.

Históricamente, los pronósticos de demanda eléctrica han sido objeto de estudio desde la década de 1970 (González Andrade, 2010). En sus inicios, se aplicaron principalmente modelos estadísticos y matemáticos clásicos, tales como regresión múltiple, suavizamiento exponencial, mínimos cuadrados ponderados, modelos ARMAX o series temporales estocásticas (Lofuto & Minussini, 1999). Al ser lineales, dichos modelos asumen que la relación entre las variables es consistente en el tiempo, dejando sesgado las variaciones significativas que puedan ocurrir por cualquier elemento externo no considerado en el modelo. La propia arquitectura termina enseñando las debilidades de dichos modelos cuando son puestos a prueba con escenarios reales más complejos con cambios bruscos y patrones no lineales, esto se debe a que toman de supuesto que el futuro se puede explicar como una combinación lineal de los valores pasados; esto implica que la relación entre valores pasados y futuros es proporcional y no existen cambios bruscos entre ellos.

Los modelos estadísticos clásicos, como ARIMA, exigen rigurosamente que la serie temporal sea estacionaria, lo que implica que su media y varianza deben permanecer constantes a lo largo del tiempo. Sin embargo, la demanda eléctrica es, por definición, un fenómeno no estacionario: presenta tendencias de crecimiento a largo plazo impulsadas por la electrificación y el aumento poblacional, así como una varianza que fluctúa drásticamente según la estación (por ejemplo, la volatilidad en verano suele ser superior a la del otoño debido al uso intensivo de sistemas de aire acondicionado). Estas características limitan severamente la precisión de los modelos lineales en escenarios reales.

El desarrollo del aprendizaje automático (Machine Learning) marcó un punto de inflexión para superar estas barreras. Las Redes Neuronales Recurrentes (RNN) se posicionaron como una solución eficaz para modelar la no linealidad inherente al sistema. Específicamente, arquitecturas avanzadas como la Memoria a Corto y Largo Plazo (LSTM) y la Unidad Recurrente con Compuerta (GRU) fueron diseñadas para resolver las deficiencias de las RNN tradicionales (como el desvanecimiento del gradiente). Estas

arquitecturas poseen una “memoria interna” que les permite procesar secuencias de datos, aprendiendo teóricamente dependencias temporales a largo plazo que los modelos estadísticos ignoran.

La adopción de estos modelos no lineales es particularmente crítica en el contexto de México, donde la demanda eléctrica es altamente sensible a efectos climáticos complejos. Existe una relación no lineal comprobada entre la temperatura y el consumo: la demanda nacional tiende a dispararse cuando la temperatura asciende por encima de los 30°C (uso de refrigeración) o desciende por debajo de los 12°C (uso de calefacción). Capturar estos “efectos de umbral” es esencial para un pronóstico preciso, y es una tarea donde las redes neuronales superan ampliamente a las aproximaciones lineales. (German-Soto et al., 2025).

Esta investigación se sustentará en N-BEATS (Neural Basis Expansion Analysis for Time Series Forecasting) que representa un cambio de paradigma en el pronóstico de series temporales al demostrar que una arquitectura de Deep Learning pura, basada exclusivamente en redes neuronales totalmente conectadas (FC-layers), puede superar en rendimiento a los modelos estadísticos clásicos y a arquitecturas híbridas complejas.

El modelo N-BEATS es una arquitectura de redes neuronales diseñada específicamente para pronósticos de series temporales. A diferencia de otros enfoques más complejos, N-BEATS trabaja únicamente con los datos históricos de la propia serie y es capaz de aprender automáticamente patrones internos, como la tendencia y la estacionalidad, sin necesidad de variables externas o transformaciones adicionales. Su estructura se basa en bloques que descomponen la serie en partes interpretables, como tendencias y ciclos, y reconstruyen el pronóstico de forma precisa.

El modelo N-BEATS se ha consolidado como una alternativa robusta para el pronóstico de series temporales debido a su desempeño frente a los estándares establecidos por la competencia M4, organizada en 2018 y compuesta por 100 000 series reales con frecuencias anual, trimestral, mensual, semanal y diaria, provenientes de diversos dominios. Aunque N-BEATS no participó oficialmente en dicha competencia, fue evaluado posteriormente utilizando los mismos conjuntos de datos y condiciones experimentales. Los resultados mostraron mejoras de hasta un 11 % en precisión respecto al modelo ganador de la M4, lo que evidencia su eficacia y potencial en tareas de pronóstico. (Oreshkin et al., 2019).

Palabras clave

Pronóstico de demanda eléctrica, series temporales, redes neuronales profundas, N-BEATS

Enunciado del problema de investigación

El pronóstico de la demanda eléctrica constituye un elemento fundamental para la planificación, operación y optimización de los sistemas de energía, ya que permite anticipar necesidades de generación, distribución y consumo de manera eficiente. Tradicionalmente, esta labor se ha apoyado en modelos estadísticos recursivos como ARIMA, ARMAX o SARIMAX, los cuales dependen de supuestos fuertes de linealidad, estacionariedad y estructura temporal fija. Estos modelos representan limitaciones importantes ante escenarios reales caracterizados por patrones complejos, alta variabilidad y múltiples factores exógenos que afectan la demanda; su capacidad para capturar relaciones no lineales, efectos de largo plazo y dinámicas estacionales múltiples es restringida, comprometiendo su desempeño.

En este contexto, surge la necesidad de evaluar un modelo como N-BEATS desde una perspectiva aplicada. El interés radica en demostrar la utilidad del modelo en un escenario auténtico de pronóstico de demanda eléctrica, empleando datos reales y validando su desempeño mediante métricas estándar del sector, como MAPE y RMSE, para determinar si puede ofrecer una precisión superior o más consistente que los enfoques recursivos tradicionales.

Objetivos de la investigación

Objetivo general

Desarrollar, validar e implementar un modelo de pronóstico basado en la arquitectura N-BEATS (univariado) para la demanda eléctrica, utilizando datos históricos reales, de modo que el pronóstico alcance un $\text{MAPE} \leq 5\%$ en pruebas fuera de muestra y muestre desempeño robusto según métricas estándar (MAPE, RMSE).

Objetivos específicos

- **Implementar y configurar la arquitectura de red neuronal profunda N-BEATS**, optimizando sus bloques de tendencia y estacionalidad para capturar automáticamente los patrones no lineales de la demanda eléctrica sin dependencia de variables externas.
- **Validar el modelo con datos reales de consumo eléctrico** mediante proyecciones fuera de muestra (out-of-sample), evaluando su error de pronóstico en escenarios operativos simulados
- **Establecer un baseline mínimo para referencia funcional**, un modelo trivial o clásico de referencia (ARIMA simple o LSTM) sólo como punto de referencia
- **Desarrollar una aplicación ejecutable que implemente el modelo propuesto**, permitiendo realizar pronósticos de demanda eléctrica de manera automatizada y accesible.

Justificación

La capacidad de realizar pronósticos de demanda eléctrica precisos es un requisito indispensable para la planificación y operación eficiente de los sistemas de energía. La falta de precisión en estas estimaciones puede derivar en graves consecuencias: una sobreestimación implica un exceso de energía en el sistema, lo cual genera perturbaciones en el equilibrio eléctrico que pueden dañar equipos de generación y dispositivos conectados; mientras que una subestimación conlleva insuficiencia en el suministro, lo que incrementa el riesgo de apagones, sobrecargas y fallas en la distribución.

En México, estas fallas se han repetido en diversas regiones durante los últimos años, destacando el caso reciente de apagones en Yucatán, donde las temperaturas extremas elevaron de forma abrupta el consumo doméstico y superaron la capacidad de la infraestructura local, evidenciando deficiencias en transmisión y distribución (Ramírez, 2025). Esta situación se agrava porque el país opera con una reserva eléctrica cercana al 7%, lo que limita su capacidad para responder a incrementos inesperados en la demanda. Datos del Centro Nacional de Control de Energía muestran que varias zonas consumen más energía de la que pueden generar,

un desequilibrio que ha derivado en apagones prolongados y que representa un costo estimado de cerca de 9 mil millones de pesos, consecuencias que pudieron mitigarse mediante pronósticos que integraran variables críticas como clima, variaciones estacionales y patrones de consumo residencial e industrial (Contreras, 2025).

Es evidente para este punto sostener que la complejidad de un pronóstico de demanda eléctrica reside en la influencia de patrones no lineales, multivariados y altamente estacionales, así como variables externas que interactúan entre sí (temperatura, humedad, calendario, ciclos de actividad humana). Tradicionalmente se ha modelado con enfoques lineales como ARIMA, regresión múltiple o modelos SARIMA, los cuales funcionan bien en escenario simples, pero presentan limitaciones estructurales frente a la complejidad real del sistema eléctrico moderno.

Investigaciones recientes, como el estudio comparativo sobre la demanda energética en Nigeria (2015-2022), han evaluado la capacidad predictiva de modelos estocásticos frente a arquitecturas de aprendizaje profundo. Los resultados empíricos revelaron un hallazgo contraintuitivo: la arquitectura RNN básica superó a la red avanzada LSTM en todas las métricas de evaluación. Este fenómeno se atribuye a la limitación del volumen de datos; el conjunto de entrenamiento (menos de 100 observaciones mensuales) resultó insuficiente para optimizar la elevada densidad paramétrica de una LSTM, mientras que la RNN, al ser estructuralmente más simple, logró generalizar mejor los patrones de tendencia.

De manera complementaria, el mismo análisis evidenció que el modelo estadístico lineal ARIMA también superó en precisión a la arquitectura LSTM. Este resultado es crítico, pues valida la robustez y vigencia de los modelos lineales tradicionales en escenarios de *Small Data*, demostrando que la sofisticación algorítmica del Aprendizaje Profundo puede ser contraproducente si no se cuenta con la densidad histórica suficiente para justificar su aplicación.

La evidencia de Nigeria muestra que las arquitecturas recurrentes tradicionales (LSTM) pueden fallar en contextos de datos limitados. Frente a esto, N-BEATS, al ser una arquitectura basada en bloques residuales y no recurrente, evita los problemas de desvanecimiento de gradiente y ha demostrado en la literatura ser más eficiente en el entrenamiento y la generalización, ofreciendo una solución técnica a las limitaciones de rendimiento observadas con LSTM.

Por otro lado, un estudio sobre la predicción de la Fiebre Hemorrágica con Síndrome Renal (HFRS) en China demostró que, si bien ARIMA fue superior en escalas mensuales y semanales (donde predominan patrones lineales), esta dinámica se invirtió en la escala diaria. En alta frecuencia, LSTM capturó mucho mejor la volatilidad y las fluctuaciones no lineales que la rigidez matemática de ARIMA no pudo modelar.

Estos resultados sugieren que un modelo robusto debe ser capaz de manejar explícitamente la estacionalidad (donde ARIMA brilla) sin perder la capacidad de modelar volatilidad (donde el Deep Learning gana). N-BEATS aborda este desafío mediante sus bloques interpretables de tendencia y estacionalidad, combinando la transparencia de los métodos estadísticos con la potencia no lineal del aprendizaje profundo.

Dado que la demanda eléctrica moderna presenta componentes tanto de baja frecuencia (tendencias anuales) como de alta frecuencia (perfiles diarios volátiles), la arquitectura N-BEATS se posiciona como una alternativa superior e integradora frente a la dicotomía tradicional de elegir entre ARIMA o LSTM.

Los beneficiarios potenciales de este trabajo abarcan múltiples sectores: las empresas generadoras y distribuidoras de electricidad, que podrán optimizar sus procesos de planificación y operación; los grandes consumidores de energía, que dispondrán de proyecciones más confiables para gestionar su consumo; y, en un plano más amplio, la sociedad en general, que se beneficiará de un sistema eléctrico más estable,

eficiente y sostenible, en consonancia con los objetivos de transición energética y de integración de fuentes renovables.

Bosquejo de marco de referencia / marco teórico

La investigación discutirá primero los conceptos generales asociados al análisis de series temporales, incluyendo elementos esenciales como tendencia, estacionalidad, componentes cíclicos y ruido, que resultan fundamentales para caracterizar el comportamiento de la demanda eléctrica. Posteriormente, se revisarán los modelos estadísticos tradicionales utilizados en este campo, tales como ARIMA, destacando sus alcances y limitaciones operativas en contextos no estacionarios.

Se abordarán las arquitecturas de redes neuronales aplicadas a series temporales, como LSTM y GRU, explicando su capacidad para modelar dependencias no lineales y patrones complejos que los enfoques lineales no capturan adecuadamente. El interés es profundizar en la arquitectura N-BEATS como modelo de aprendizaje profundo orientado específicamente al pronóstico univariado sin necesidad de variables exógenas, enfatizando su diseño basado en bloques, su capacidad para descomponer patrones internos y su posicionamiento como una alternativa competitiva.

El marco teórico incluirá los criterios estándar para evaluar modelos de pronóstico de demanda eléctrica, particularmente métricas como MAPE, RMSE y MAE, explicando su interpretación y relevancia operativa en escenarios reales.

Se presentarán las variables que estructuran la investigación de la siguiente forma:

- **Variables Dependientes**
 - Demanda eléctrica
- **Variables Independientes.** Dado que N-BEATS opera de forma univariada, las variables se derivan del propio comportamiento interno de la serie:
 - Tendencia
 - Estacionalidad
 - Patrones internos y ciclos recurrentes
 - Ruido estocástico y variaciones no lineales

Con ello, el marco teórico establecerá las bases conceptuales y metodológicas que justifican la elección de N-BEATS como modelo central de estudio y permitirá situar esta investigación dentro del panorama contemporáneo del pronóstico eléctrico.

Hipótesis

El modelo N-BEATS muestra un desempeño predictivo adecuado para la demanda eléctrica, reflejado en métricas estándar (MAPE, RMSE, MAE) que se encuentran dentro de los rangos aceptados para pronósticos de corto plazo en sistemas eléctricos.

Bosquejo del método

Determinación del universo y obtención de la muestra

El universo de estudio está constituido por los valores históricos de demanda eléctrica registrados en los laboratorios y áreas operativas de la institución. La muestra estará conformada por un conjunto de series temporales de consumo eléctrico obtenidas directamente de los sistemas de medición utilizados por la

universidad. Dichos datos incluirán valores horarios o subhorarios, según la disponibilidad, correspondientes a un periodo continuo suficiente para capturar patrones internos relevantes como tendencia, estacionalidad y ciclos de consumo.

Determinación del tipo de investigación

La investigación será cuantitativa y se clasificará como aplicada, ya que se busca evaluar la eficacia real de un modelo de redes neuronales profundas para generar pronósticos útiles en un entorno operativo. El diseño será no experimental, dado que los datos se analizan sin manipulación de variables y se observan tal como ocurren históricamente.

Selección, diseño y prueba del instrumento de recolección

La recolección de información se basará en registros digitales proporcionados por la institución; por lo tanto, el instrumento corresponde al conjunto de herramientas de extracción y depuración de datos. Se diseñarán scripts para:

- Limpieza y validación de consistencia
- Normalización de formatos
- Detección y manejo de valores atípicos o faltantes
- Segmentación de los datos en conjuntos de entrenamiento, validación y prueba

Plan de recolección de información

La obtención de los datos se llevará a cabo mediante solicitud formal a la universidad, asegurando acceso a los registros históricos de consumo eléctrico. Posteriormente, los datos serán organizados cronológicamente y se construirá la base utilizada para el entrenamiento del modelo. Se aplicarán procesos estándar de preparación de series temporales: resampleo, escalamiento, verificación de integridad y segmentación en ventanas temporales para la predicción.

Plan de procesamiento y análisis de información

El análisis consistirá en las siguientes etapas:

1. Entrenamiento del modelo N-BEATS
 - Configuración de bloques de tendencia y estacionalidad
 - Ajuste de hiperparámetros
 - Entrenamiento con datos históricos mediante técnicas de validación fuera de muestra
2. Establecimiento de un baseline
 - Implementación mínima de un modelo clásico (ARIMA simple o LSTM básico) exclusivamente como referencia funcional
3. Evaluación mediante métricas estándar
 - Cálculo del MAPE, RMSE y MAE para medir la precisión del pronóstico
 - Comparación del desempeño de N-BEATS contra el baseline seleccionado
4. Análisis interpretativo
 - Identificación de patrones internos capturados por el modelo
 - Revisión de errores sistemáticos o condiciones en las que el desempeño se degrade
 - Discusión del potencial uso operativo del modelo en escenarios reales de planeación energética

Gestión del proyecto

Etapa 1. Preparación teórica y metodológica

Actividad	Duración estimada	Objetivo
Revisión de literatura sobre series temporales, demanda eléctrica y modelos clásicos (ARIMA, SARIMA, LSTM)	2 semanas	Establecer el estado del arte y comprender las limitaciones de los modelos recursivos tradicionales.
Revisión específica del modelo N-BEATS y estudios comparativos recientes	1 semana	Fundamentar la pertinencia del modelo N-BEATS para la demanda eléctrica.
Redacción del marco teórico e hipótesis	1 semana	Definir los conceptos base, las variables del estudio y la hipótesis a verificar.
Diseño metodológico inicial	1 semana	Establecer el tipo de investigación, universo, muestra e instrumentos de recolección y procesamiento de datos.

Etapa 2. Obtención y preparación de datos

Actividad	Duración estimada	Objetivo
Solicitud formal y obtención de los datos reales de consumo eléctrico de la institución	1 semana	Asegurar la disponibilidad de datos confiables para entrenar el modelo.
Limpieza, depuración, manejo de faltantes y reconstrucción de la serie	1 semana	Garantizar integridad y consistencia de los registros para análisis.
Transformaciones iniciales (resampleo, normalización, creación de ventanas temporales)	1 semana	Preparar los datos en el formato operacional requerido por N-BEATS.

Etapa 3. Modelado y evaluación

Actividad	Duración estimada	Objetivo
Implementación inicial del modelo N-BEATS (configuración de bloques, arquitectura base)	2 semanas	Construir la primera versión funcional del modelo.
Entrenamiento con datos históricos y ajustes de hiperparámetros	2 semanas	Optimizar el desempeño del modelo mediante iteraciones controladas.
Implementación del baseline (ARIMA o LSTM simple)	1 semana	Contar con un punto de comparación para evaluar la mejora obtenida.
Evaluación del modelo mediante MAPE, RMSE y MAE	1 semana	Medir la precisión, estabilidad y relevancia práctica del modelo.
Interpretación de resultados y análisis comparativo contra el baseline	1 semana	Identificar fortalezas, limitaciones y condiciones de desempeño óptimo.

Etapa 4. Desarrollo de la aplicación de escritorio

Actividad	Duración estimada	Objetivo
Diseño de la estructura de la aplicación (UI simple, flujo de carga/ejecución)	1 semana	Definir la arquitectura básica del software.

Integración del modelo N-BEATS entrenado en la aplicación	1 semana	Permitir la ejecución automática de pronósticos.
Implementación de visualizaciones, métricas y exportación de resultados	1 semana	Facilitar al usuario final la interpretación y uso del modelo.
Pruebas internas, corrección de errores y optimización	1 semana	Garantizar funcionalidad, estabilidad y buena experiencia de uso.

Etapa 5. Redacción, revisión y entrega del informe final

Actividad	Duración estimada	Objetivo
Redacción del documento final (metodología, resultados, anexos)	2 semanas	Integrar todas las etapas del proyecto en un informe académico completo.
Revisión del informe con asesor y ajustes finales	1 semana	Realizar mejoras argumentativas, metodológicas y de estilo.
Preparación de anexos, código, capturas de la aplicación y versión final	1 semana	Completar el documento y dejarlo listo para la entrega oficial.

Productos entregables

La investigación generará producto principal una aplicación de escritorio capaz de realizar pronósticos de demanda eléctrica a partir de series históricas proporcionadas por el usuario. Esta herramienta integrará el modelo N-BEATS desarrollado y validado en el proyecto, permitiendo ejecutar predicciones de manera automatizada y accesible.

La aplicación incluirá las siguientes funcionalidades:

- Carga de datos mediante archivos en formato estándar (CSV o similares)
- Procesamiento automático de la serie ingresada, incluyendo normalización, verificación de consistencia y preparación de ventanas temporales para pronóstico
- Visualización gráfica de la serie histórica y del pronóstico para facilitar su interpretación
- Reporte de métricas de desempeño (MAPE, RSME y MAE) para evaluar la precisión del modelo sobre nuevos conjuntos de datos

Además del software, el proyecto entregará:

- El modelo entrenado junto con su configuración final e hiperparámetros
- Un informe técnico que documentará el proceso de desarrollo, validación y evaluación del modelo, así como las conclusiones derivadas del análisis
- Código fuente documentado, facilitando su reutilización y futuras ampliaciones

Vinculaciones estratégicas y lugar(es) de desarrollo del proyecto

El proyecto se desarrollará principalmente en las instalaciones del Instituto Tecnológico de Morelia, dentro del Departamento de Sistemas y Computación, donde se llevará a cabo el procesamiento de datos, la implementación del modelo N-BEATS y el desarrollo de la aplicación de escritorio.

Para garantizar la obtención confiable y fortalecer la pertinencia del estudio, se establecerá una vinculación estratégica con el Departamento de Ingeniería Eléctrica de la institución. Esta colaboración permitirá acceder a los registros históricos de demanda eléctrica de los laboratorios y áreas operativas, los cuales son

esenciales para entrenar y validar el modelo propuesto. Asimismo, esta vinculación ofrecerá retroalimentación especializada respecto a los patrones de consumo energético y a la interpretación del comportamiento real del sistema eléctrico universitario.

El proyecto podrá beneficiarse adicionalmente de la orientación de docentes y investigadores con experiencia en sistemas eléctricos, modelado energético y análisis de series temporales, lo que contribuirá al rigor técnico del trabajo y al fortalecimiento de los resultados.

Estrategias de comunicación

Para asegurar una coordinación efectiva y el acceso oportuno a los datos requeridos, se establecerán canales formales de comunicación con el Departamento de Ingeniería Eléctrica y las áreas responsables de la medición y registro del consumo eléctrico en la universidad. Esto incluirá:

- Envío de solicitudes formales para la obtención de datos históricos de demanda eléctrica
- Reuniones periódicas para aclarar requerimientos técnicos relacionados con el formato, la frecuencia o la disponibilidad de los registros
- Comunicación continua con el asesor del proyecto para supervisar el avance, validar decisiones metodológicas y garantizar el cumplimiento de los criterios académicos
- Uso de herramientas digitales para la organización del proyecto y el intercambio de información (por ejemplo, plataformas de gestión de proyectos o repositorios de código)

Estas estrategias permitirán mantener un flujo de información claro, ordenado y verificable, asegurando que los datos, recursos y aprobaciones necesarios estén disponibles en cada etapa de desarrollo de la investigación.

Fuentes consultadas

- Velásquez Henao, uan David, Dyner Resonsew, Isaac, & Castro Souza, Reinaldo. (2007). ¿Por qué es tan difícil obtener buenos pronósticos de los precios de la electricidad en mercados competitivos?. Cuadernos de Administración, 20(34), 259-282. Recuperado el 10 de octubre, 2025, de http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0120-35922007000200012&lng=en&tlng=es
- González Andrade, C. (2010). Pronóstico de la demanda en los sistemas de distribución de energía eléctrica: Aplicando la teoría de valores extremos (F. Juárez Cerrillo, Ed.) [Tesis de maestría, Universidad Veracruzana]. <https://www.uv.mx/mapli/files/2012/05/Pronostico-de-la-demanda-en-los-sistemas-de-Distribucion-de-energia-Aplicando-la-teoria-de-valores-extremos.pdf>
- Niu, S., Jia, Y., Wang, W., He, R., Hu, L., & Liu, Y. (2013). Electricity consumption and human development level: A comparative analysis based on panel data for 50 countries. International Journal Of Electrical Power & Energy Systems, 53, 338-347. <https://doi.org/10.1016/j.ijepes.2013.05.024>
- Ramírez, U. (2025, 7 mayo). ¿Qué se sabe sobre los apagones en Yucatán? Esto es lo que ocurre en Mérida. PostaMx. <https://www.posta.com.mx/yucatan/que-se-sabe-sobre-los-apagones-en-yucatan-esto-es-lo-que-ocurre-en-merida/vl2035394>
- Contreras, E. M. (2025, 14 julio). CFE advierte por apagones masivos si no se baja el consumo eléctrico; expertos señalan poca inversión del gobierno en energía, pero Sheinbaum “se defiende”. El Imparcial. <https://www.elimparcial.com/mexico/2025/07/14/cfe-advierte-por-apagones-masivos-si-no-se-baja-el-consumo-electrico-expertos-senalan-poca-inversion-del-gobierno-en-energia-pero-sheinbaum-se-defiende/>
- Germán-Soto, V., & Hernández Blanco, J. A. (2025). Efectos no-lineales del clima extremo en la demanda de electricidad regional de México. Equilibrio Económico. Revista De Economía, Política Y Sociedad, 21(60), 1-34. <https://revistas.uadec.mx/index.php/equilibrioeconomico/article/view/358>
- Oreshkin, B. N., Carpov, D., Chapados, N., & Bengio, Y. (2019). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. arXiv (Cornell University). <https://doi.org/10.48550/arxiv.1905.10437>
- Perry, B. (2025, 2 julio). How to Evaluate Power Demand Forecasts. Yes Energy. <https://www.yesenergy.com/blog/how-to-evaluate-power-demand-forecasts>